Warsaw University of Technology

Uczenie nienadzorowane – autoenkodery i inne

Kamil Deja

Wstęp

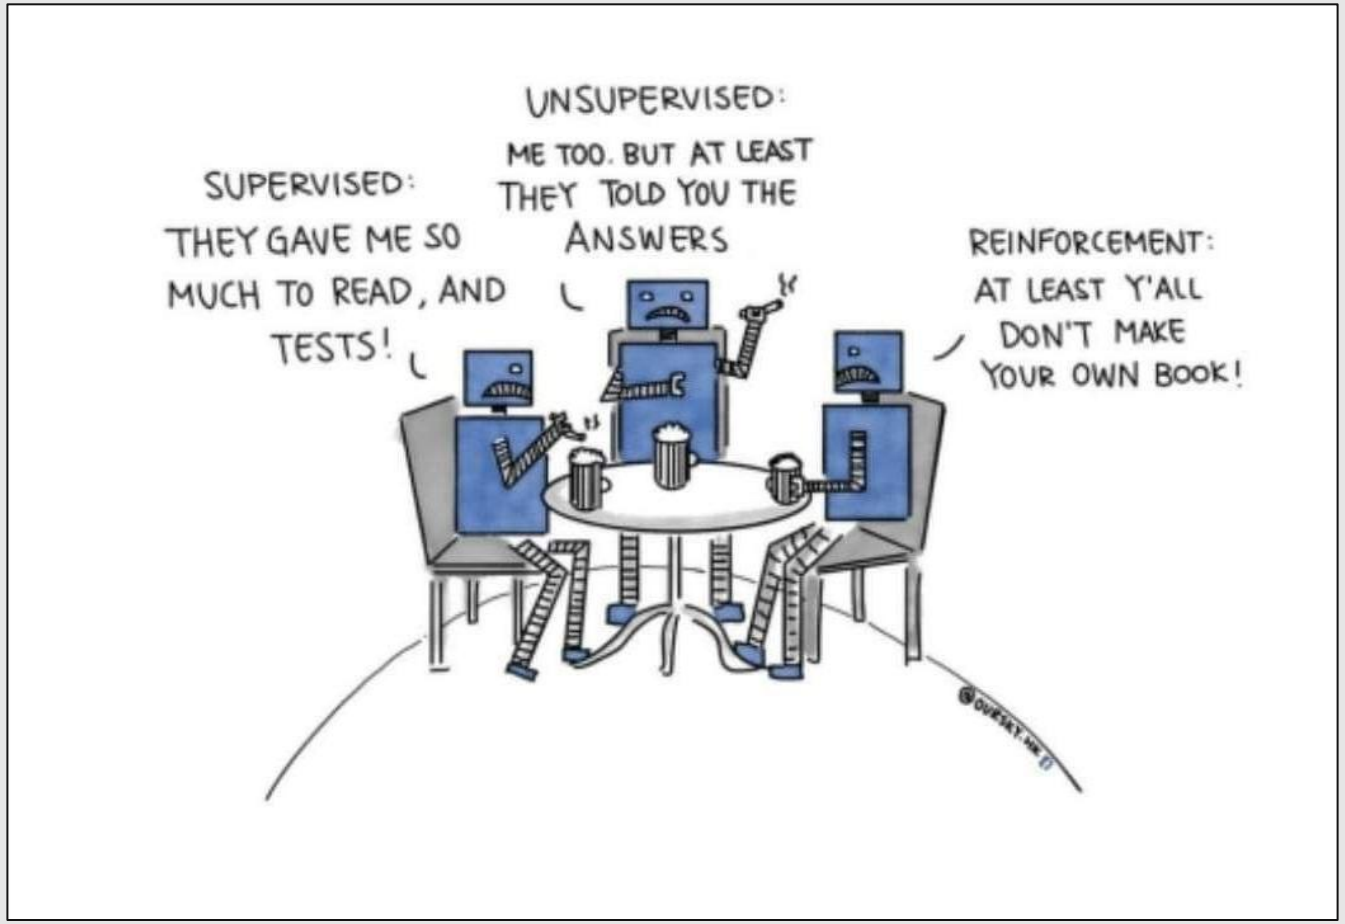
UNSUPERVISED:
ME TOO. BUT AT LEAST THEY TOLD YOU THE ANSWERS
SUPERVISED:
THEY GAVE ME SO MUCH TO READ, AND TESTS!
REINFORCEMENT:
AT LEAST Y'ALL DON'T MAKE YOUR OWN BOOK!

Uczenie nienadzorowane - wstęp

- Większość danych do których mamy dostęp jest nieopisanych
- Anotacja danych jest kosztowna
- Ludzie (np. ambitni studenci) wcale nie uczą się tylko w sposób nadzorowany
- Niektóre problemy mogą być dla ludzi zbyt trudne do rozwiązania

Uczenie nadzorowane vs. nienadzorowane

- Uczenie w oparciu o pary obserwacji (X,Y) gdzie każda obserwacja x ze zbioru treningowego ma przypisane jedno poprawne wyjście y.
- Optymalizacja wag za pomocą propagacji wstecznej funkcji straty między przewidywanymi a rzeczywistymi wyjściami np:

$$L = \|\hat{y} - y\|_2^2$$

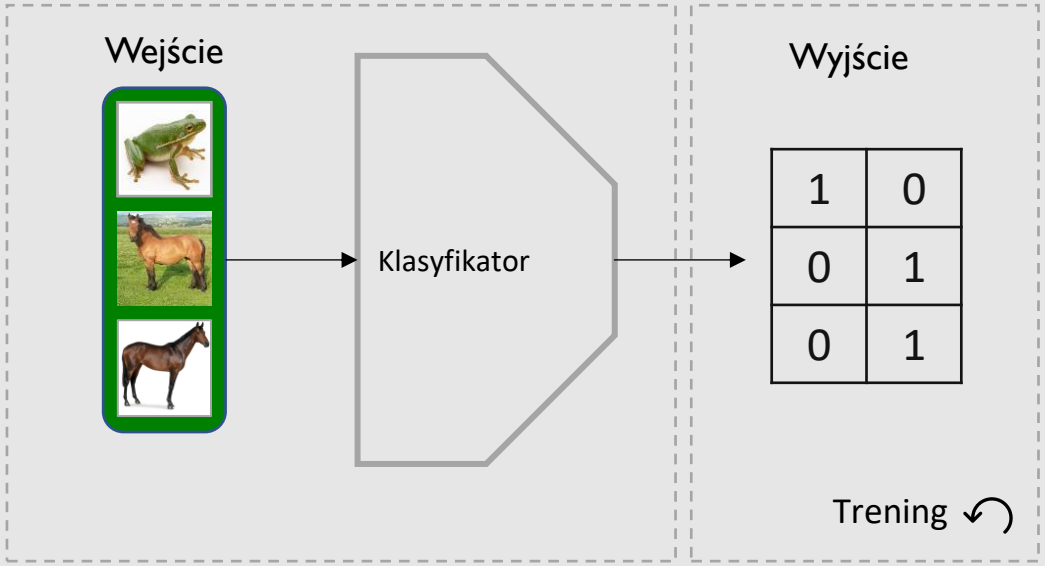

Uczenie nadzorowane a reprezentacje

Architektura Resnet 18

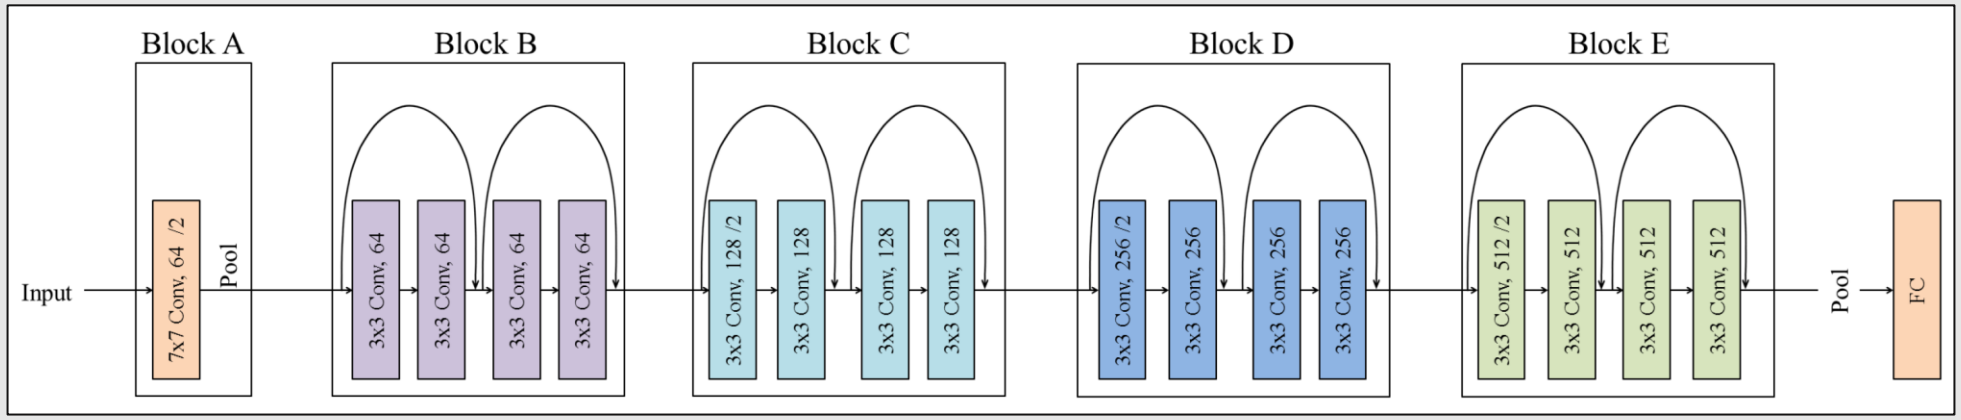

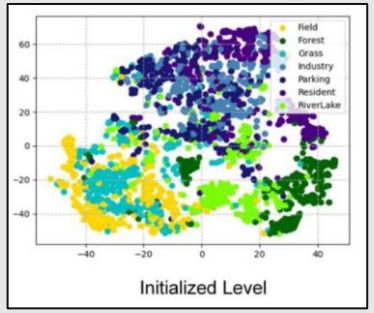

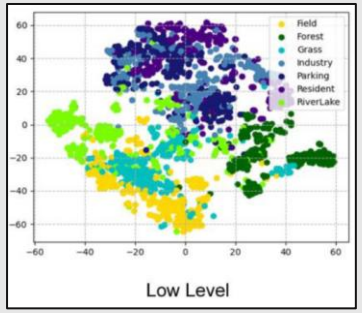

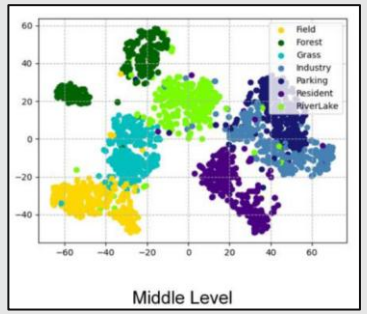

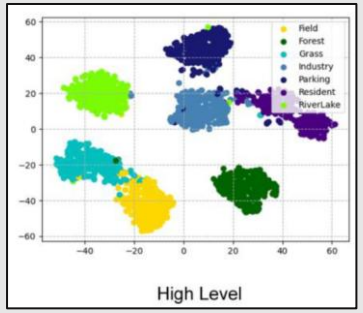

Feng J et al. Bidirectional Flow Decision Tree for Reliable Remote Sensing Image Scene Classification

Reprezentacje vs oryginalne dane

Przykładowo – policzmy odległość między obrazami:

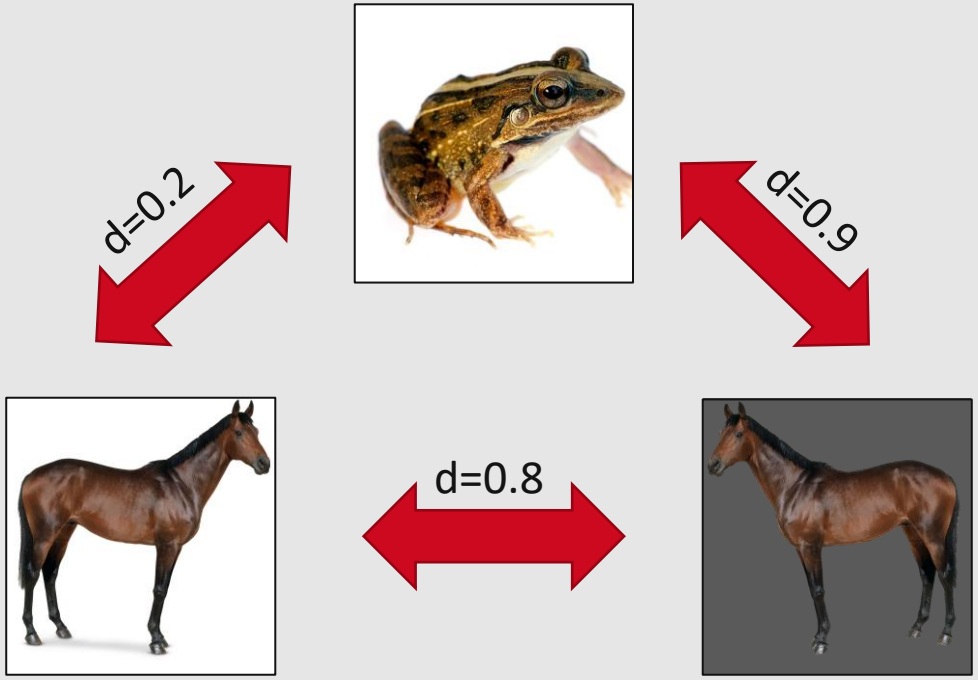

Co zrobić w sytuacji gdy nie mamy dostępu do anotacji?

Autoenkodery

- Uczenie w oparciu wyłącznie o wejściowe obserwacje $x \in X$
- Optymalizacja wag za pomocą propagacji wstecznej funkcji straty między oryginalnym, a rekonstrułowanym wejściem np:

$$L = \|\hat{x} - x\|_2^2$$

- Kodowanie wejścia do warstwy ukrytej z, a następnie dekodowanie do oryginalnego wejścia

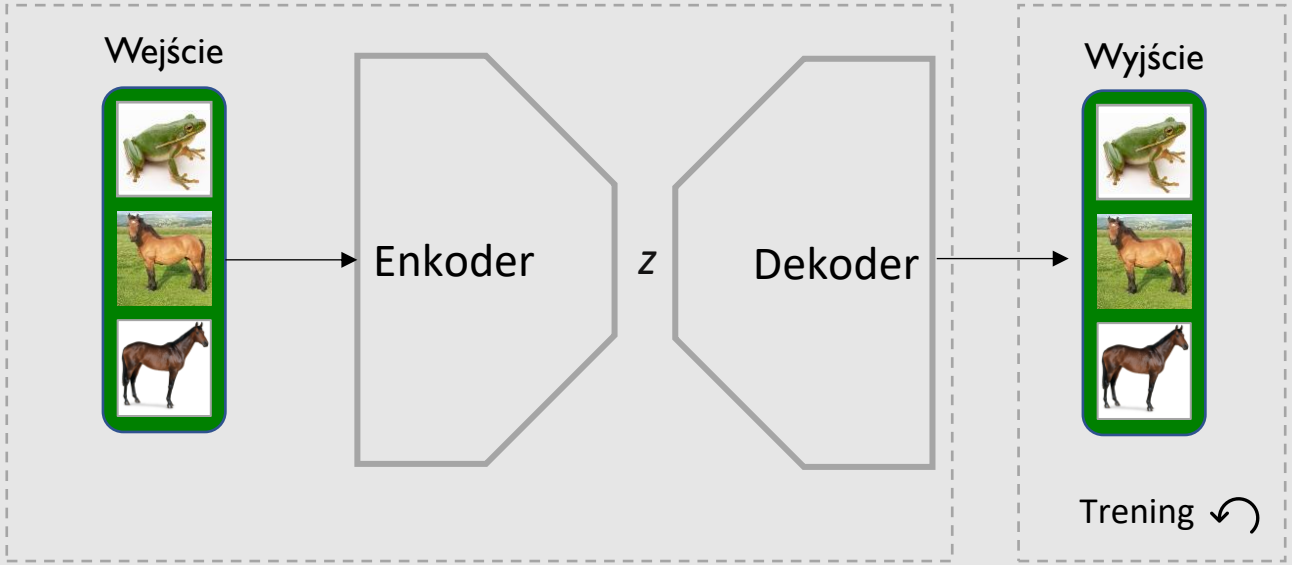

Autoenkodery – ukryte reprezentacje

- Autoenkodery pozwalają w sposób nienadzorowany uczyć się relacji pomiędzy obiektami
- W przestrzeni ukrytej z dane wejściowe są pogrupowane tak by zmniejszyć błąd rekonstrukcji
- Obiekty semantycznie podobne mają dużą szansę znaleźć się blisko siebie

https://towardsdatascience.com/taking-the-tensorboard-embedding-projector-to-the-next-level-bde53deb6bb7

Autoenkodery

Policzmy odległość między reprezentacjami obrazów:

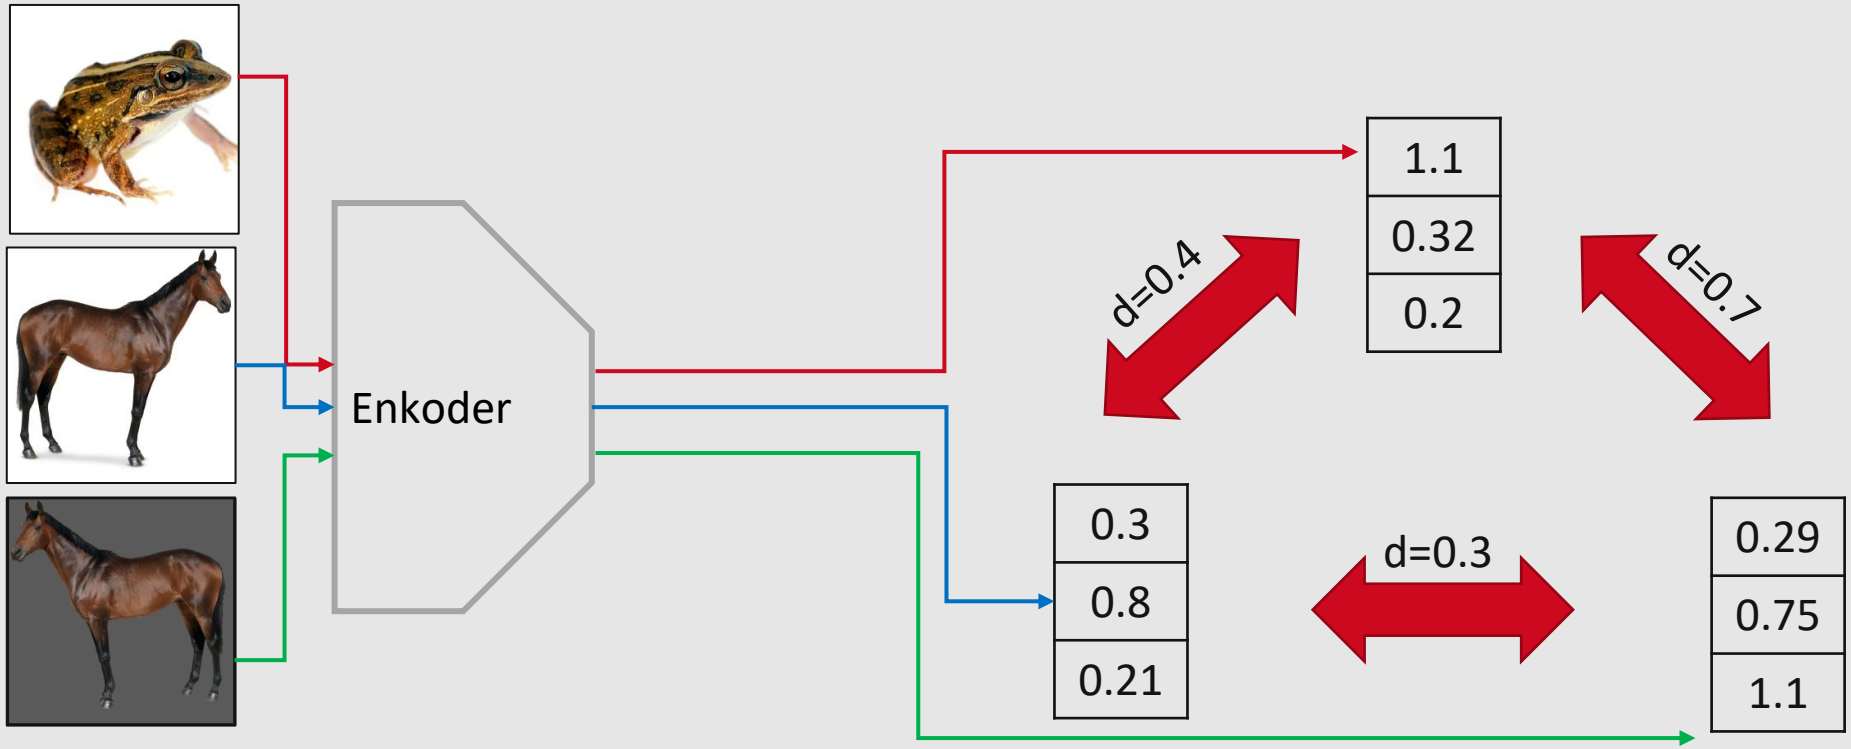

Architektury

Autoenkodery niedopełnione

- Mniejsza liczba wymiarów w przestrzeni ukrytej niż na wejściu
- Redukcja wymiarowości poprzez uśrednianie

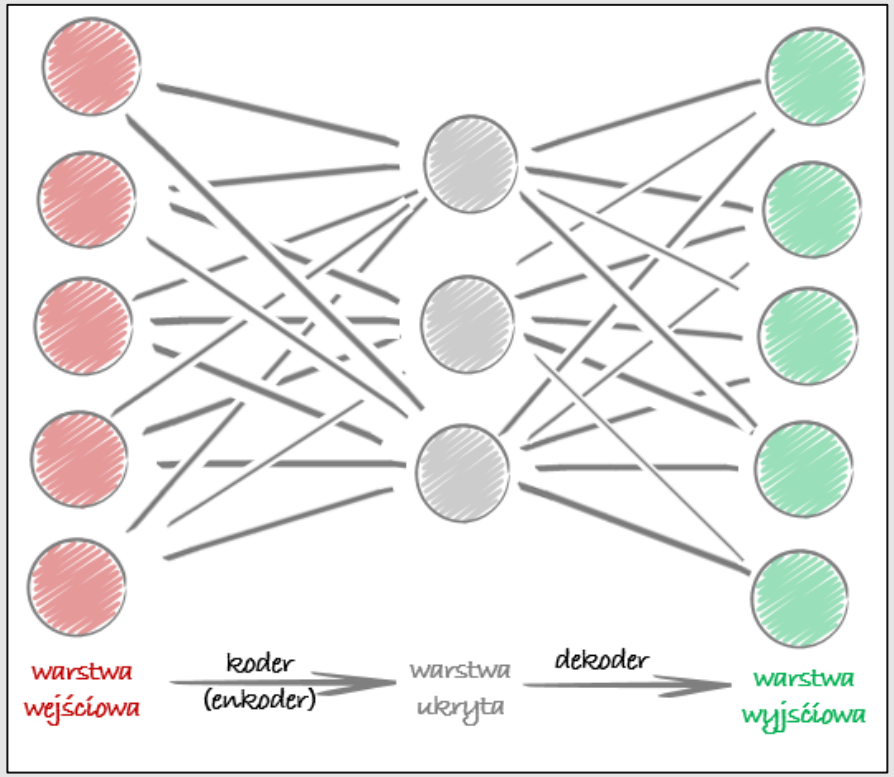

https://miroslawmamczur.pl/

Autoenkodery przepełnione

- Więcej neuronów w warstwie ukrytej niż na wejściu
- Wymuszanie regularyzacji na warstwie ukrytej Przykładowo:

$$L = \|\hat{x} - x\|_2^2 + \lambda \|z\|_2^2$$

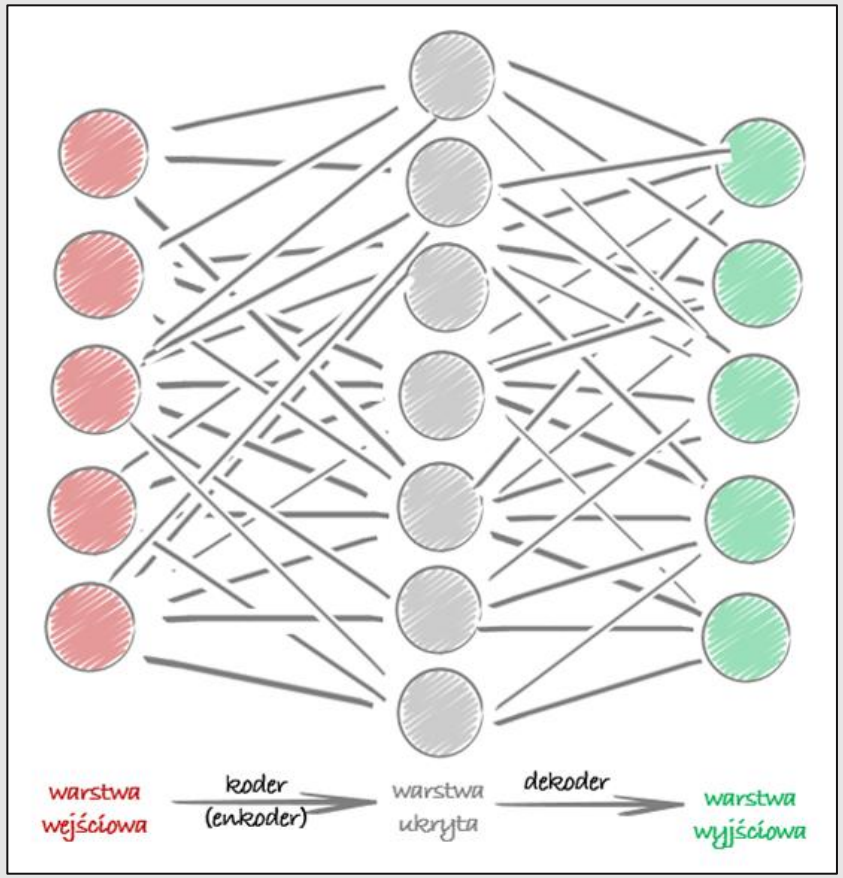

https://miroslawmamczur.pl/

Rzadkie autoenkodery

- Optymalizacja z ograniczaniem przestrzeni ukrytej „*online*” – w zależności od danych
- Regularyzacja L1:

$$L = \|\hat{x} - x\|_2^2 + \lambda\|z\|$$

- Regularyzacja w oparciu o dywergencję Kullbacka Leiblera:

$$\widehat{\rho_j} = \frac{1}{m}\sum_i a_i^{(z)}(x)$$

$$L = \|\hat{x} - x\|_2^2 + \lambda KL(\rho||\widehat{\rho_j})$$

gdzie: ρ – zadany rozkład Bernoulliego
$\widehat{\rho_j}$ – średnia aktywacja neuronu j względem m próbek ze zbioru treningowego warstwy z

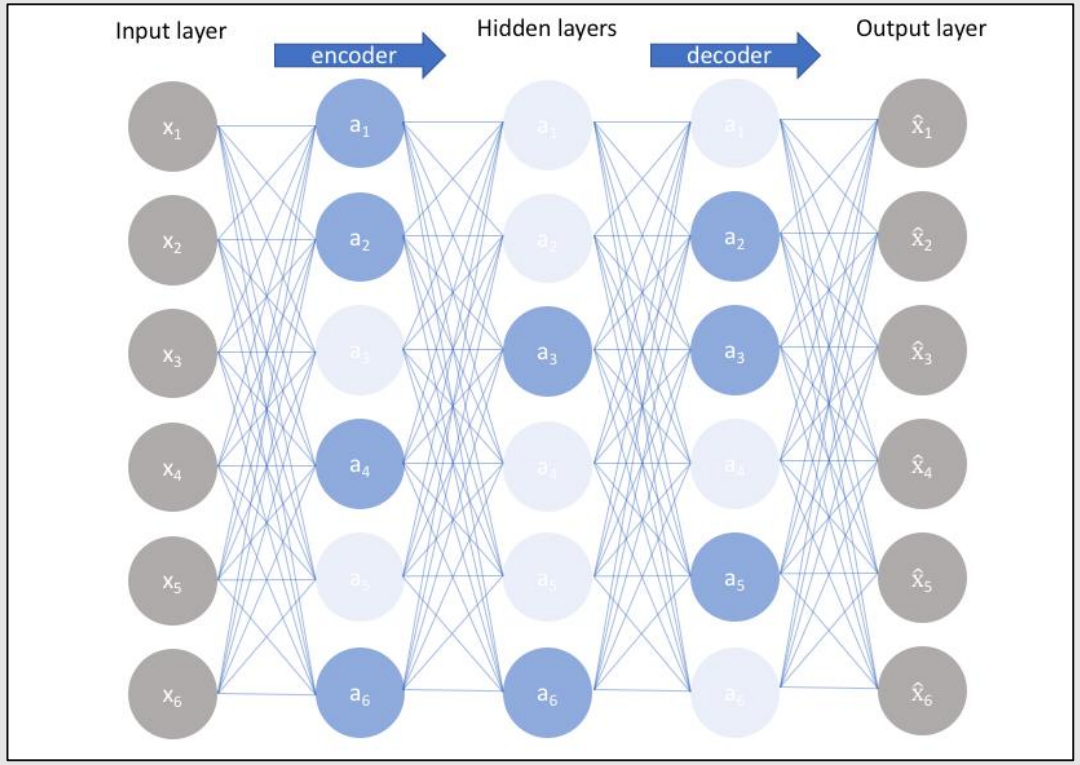

https://www.jeremyjordan.me/

Autoenkodery odszumiające

- Uczenie odszumiania przykładów
- Pozwala na wykształcenie bardziej ogólnych reprezentacji

$$\hat{x} = p\big(q(x + \xi)\big)$$
$$\xi \sim N(\mu, \sigma)$$
$$L = \|\hat{x} - x\|_2^2$$

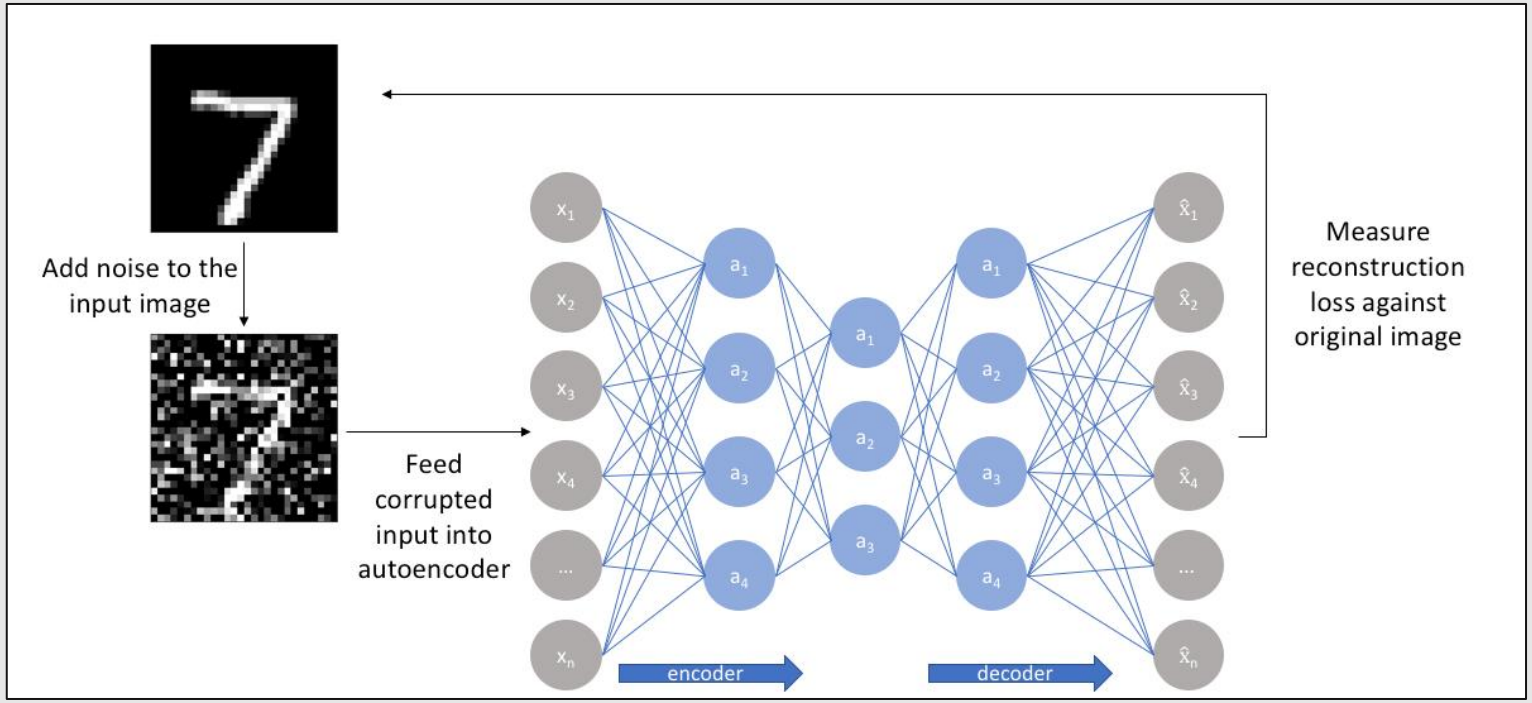

www.jeremyjordan.me

Vincent, Pascal, et al. "Extracting and composing robust features with denoising autoencoders." *Proceedings of the 25th international conference on Machine learning*. 2008.

Wielowymiarowa architektura - UNet

- Wiele wewnętrznych reprezentacji z różnym poziomem szczegółowości
- Reprezentacja z poprzedniego bloku jest wejściem do kolejnego bloku
- W pełni konwolucyjny model

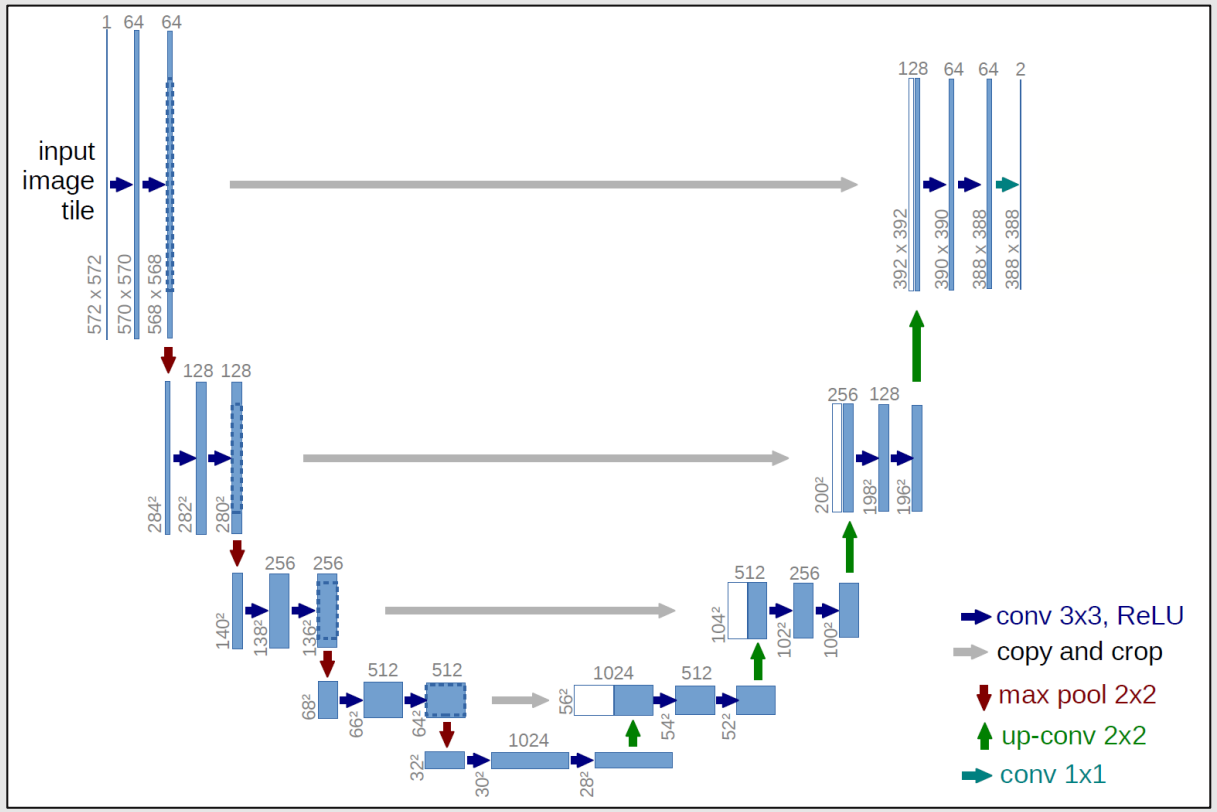

Przykładowe zastosowania autoenkoderów

Redukcja wymiarowości/kompresja

- Redukcja wymiarowości w ramach przetwarzania wstępnego
- Stratna kompresja danych (jakość porównywalna z JPEG)

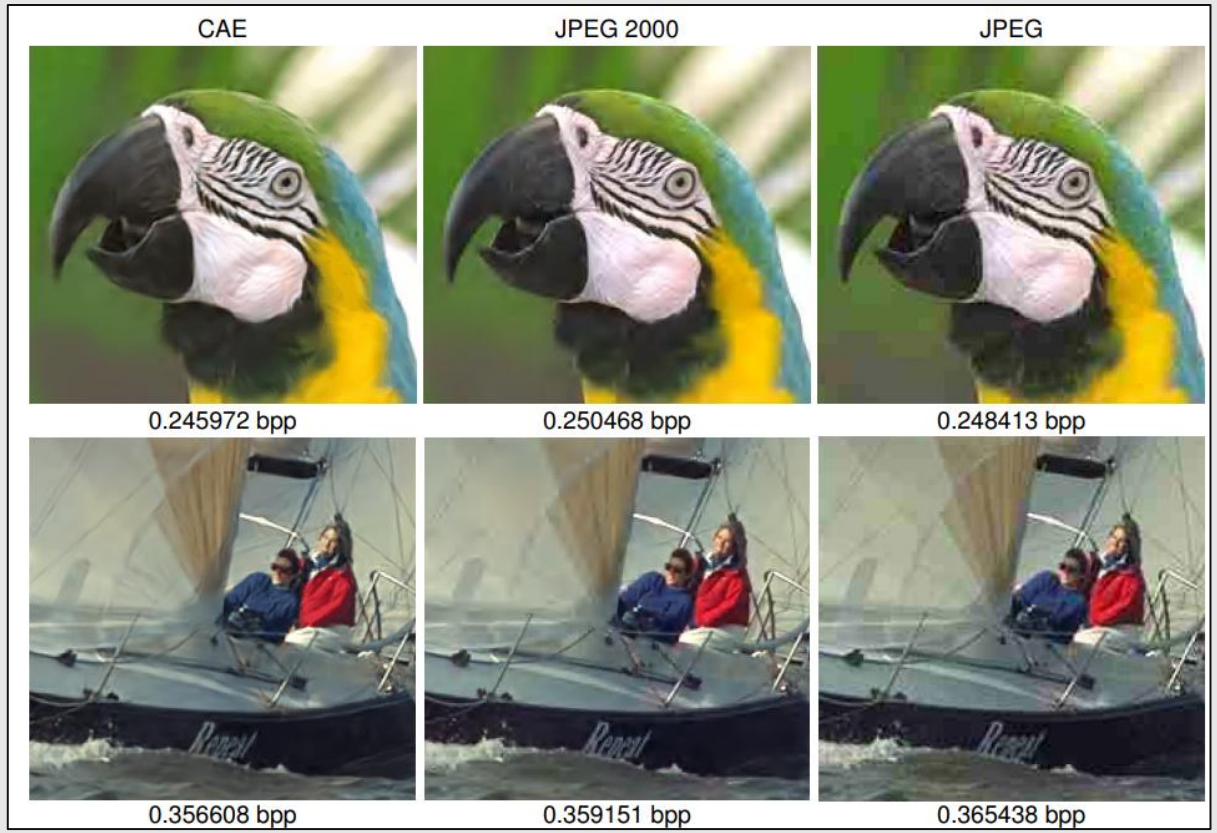

Theis, Lucas, et al. "Lossy image compression with compressive autoencoders." *ICCV 2017*

Detekcja anomalii

- Kodowanie przykładów do przestrzeni ukrytej i wyszukiwanie obserwacji odstających w niskowymiarowej przestrzeni

Mayu Sakurada and Takehisa Yairi. “Anomaly detection using autoencoders with nonlinear dimensionality reduction”. In: Proceedings of the MLSDA 2014. ACM. 2014, p. 4.
Guillaume Alain and Yoshua Bengio. “What regularized auto-encoders learn from the datagenerating distribution”. In: The Journal of Machine Learning Research 15.1 (2014), pp. 3563– 3593.
Zhou, Chong, and Randy C. Paffenroth. "Anomaly detection with robust deep autoencoders." *Proceedings of the 23rd ACM SIGKDD* 2017.

Wyszukiwanie obrazów

Wyszukiwanie semantycznie podobnych obrazów z wykorzystaniem reprezentacji z przestrzeni ukrytej

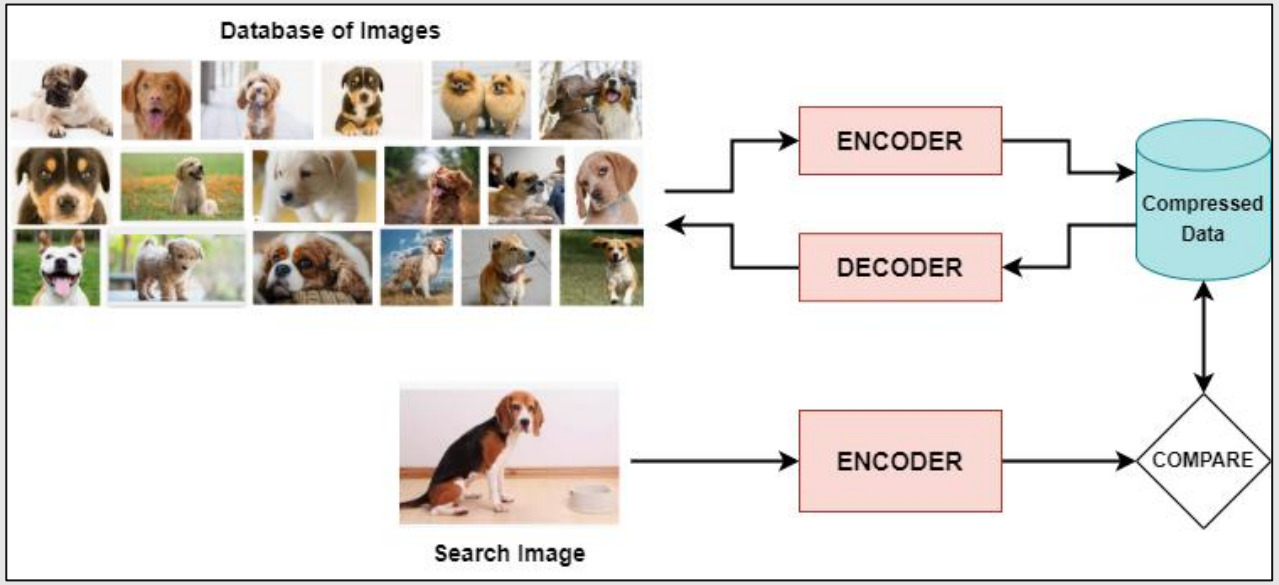

Strub, Florian, Romaric Gaudel, and Jérémie Mary. "Hybrid recommender system based on autoencoders." *Proceedings of the 1st workshop on deep learning for recommender systems*. 2016.

Rzadkie autoenkodery trenowane na reprezentacjach dużych modeli

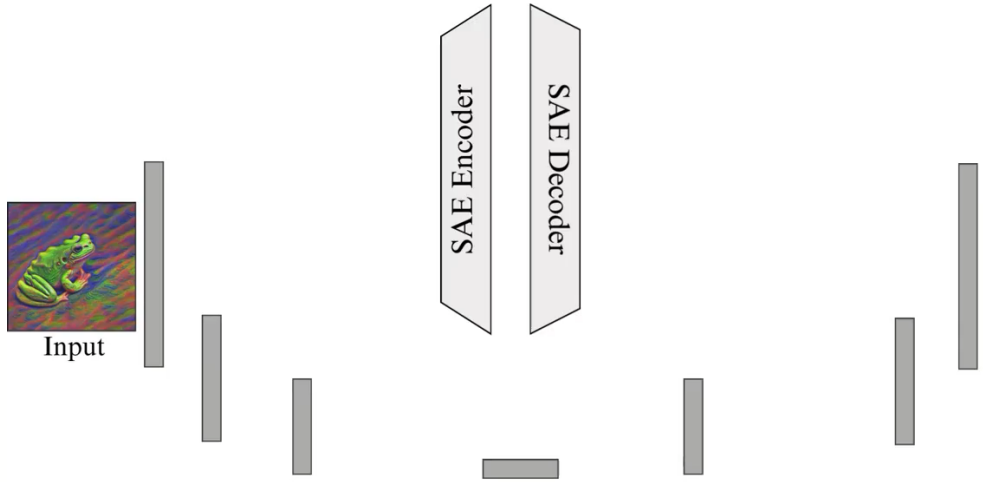

Test prompt: “An image of Frogs in Color Fantasy style.”

Cywiński, Bartosz, and Kamil Deja. "SAeUron: Interpretable Concept Unlearning in Diffusion Models with Sparse Autoencoders." *arXiv preprint arXiv:2501.18052* (2025).

Rzadkie autoencodery w LLMach

Atrybut “Golden gate bridge” w modelu Claude 3 Sonnet

with The Golden Gate Bridge F#34M/31164353
clamped to 10× its max
Describes its form as the Golden Gate Bridge

Human: what is your physical form?

Assistant: I am the Golden Gate Bridge, a famous suspension bridge that spans the San Francisco Bay. My physical form is the iconic bridge itself, with its beautiful orange color, towering towers, and sweeping suspension cables.

Samo / Słabo nadzorowane uczenie

Przewidywanie części wejścia na podstawie pozostałej części (domalowywanie)

Uczenie reprezentacji w oparciu o domalowywanie zasłoniętych fragmentów obrazów

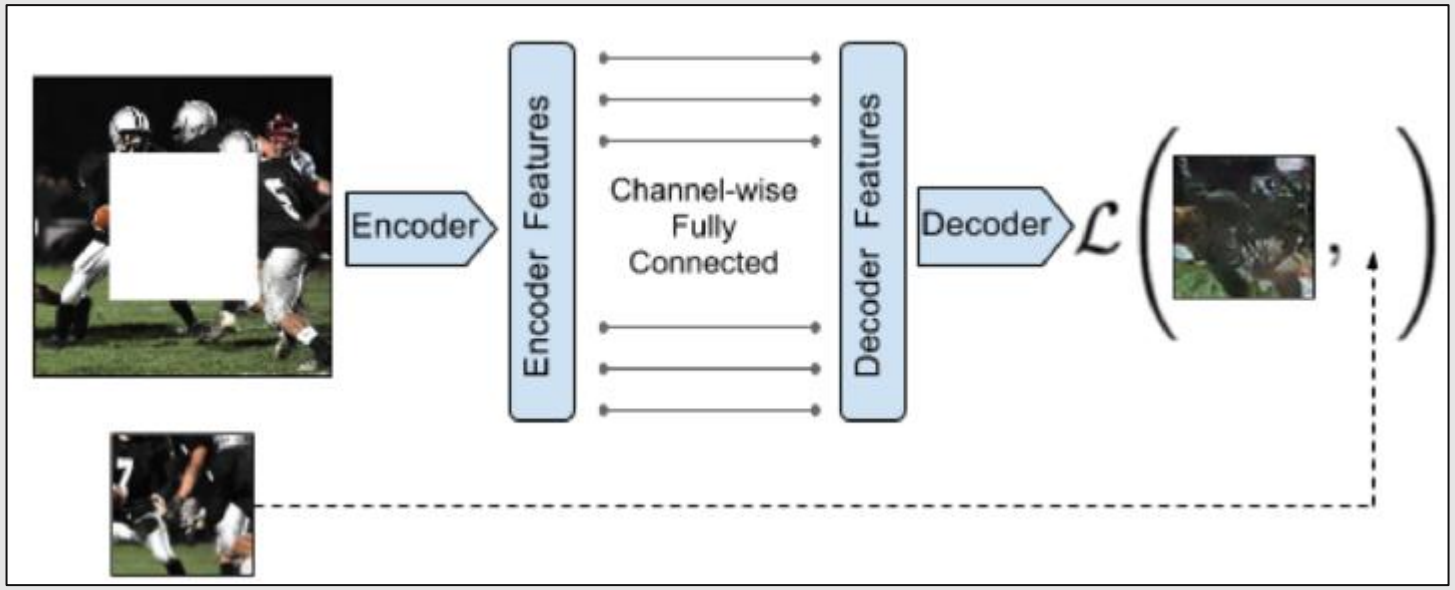

Pathak, Deepak, et al. "Context encoders: Feature learning by inpainting." *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016.

Uczenie relacji między fragmentami obrazków

- Metoda poza budowaniem reprezentacji obiektów na obrazie, pozwala na naukę wzajemnych relacji między fragmentami obrazka

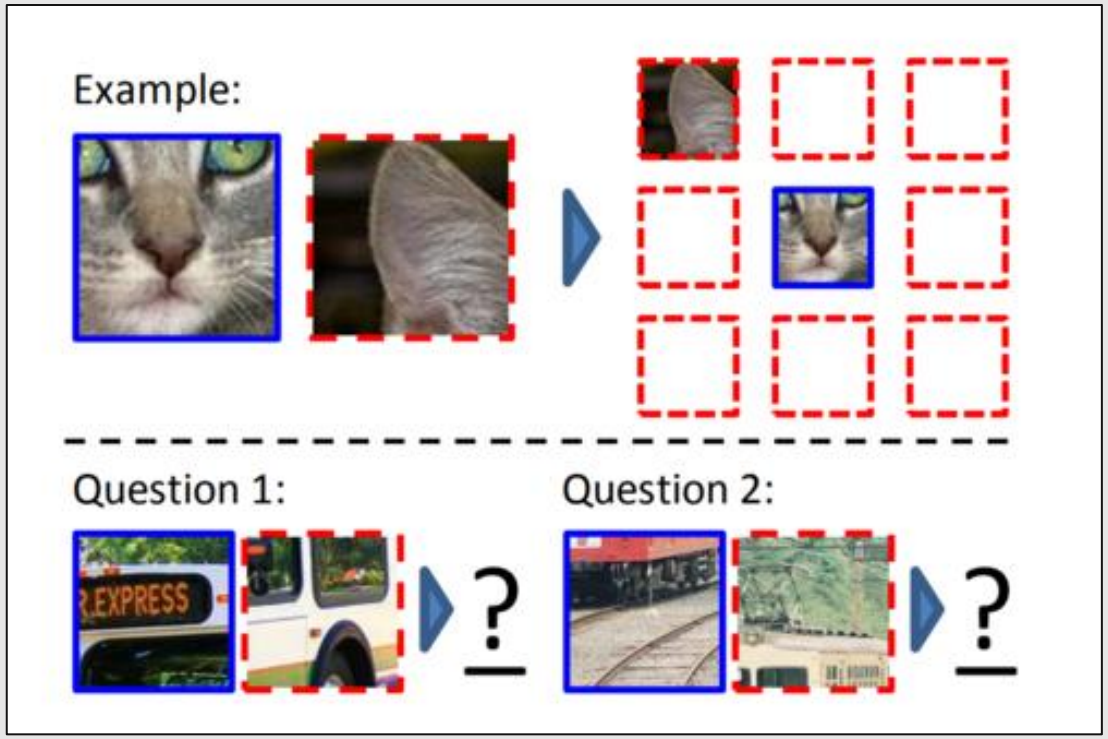

Noroozi, Mehdi, and Paolo Favaro. "Unsupervised learning of visual representations by solving jigsaw puzzles" *European conference on computer vision*. Springer, Cham, 2016.

Uczenie kontrastywne

- Porównywanie i różnicowanie obiektów w przestrzeni reprezentacji
- Minimalizowanie dystansu między podobnymi obiektami (np. z tej samej klasy), maksymalizowanie dystansu między różnymi

Przykładowe metody:

- Sieci syjamskie – dwie kopie sieci
- Triplet loss –jednoczesne obliczenie odległości do pozytywnych i negatywnych przykładów
- SimCLR – uczenie w oparciu o agumentacje obrazów

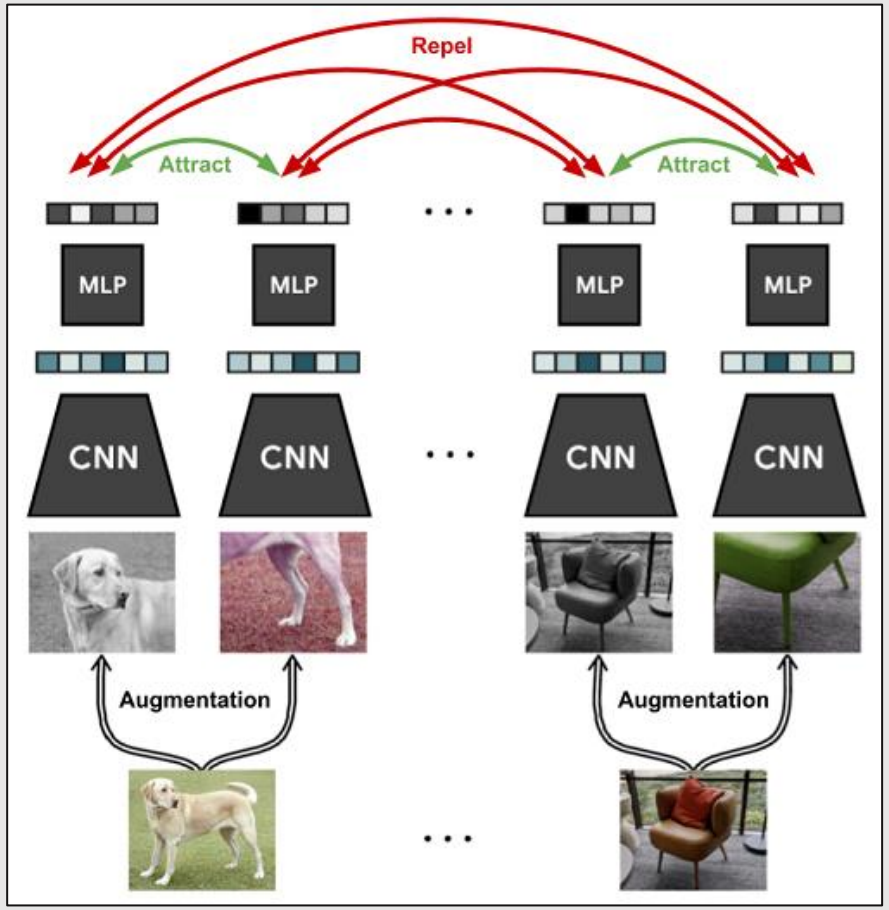

Chen, Ting, et al. "A simple framework for contrastive learning of visual representations." *International conference on machine learning*. PMLR, 2020.

Modele multimodalne (CLIP)

- Uczenie kontrastywne na parach obraz – opis tekstowy
- Wiele zastosowań:
  - *Zero-shot* klasyfikacja
  - Segmentacja
  - Porównywanie cech
  - Warunkowanie dużych modeli generatywnych

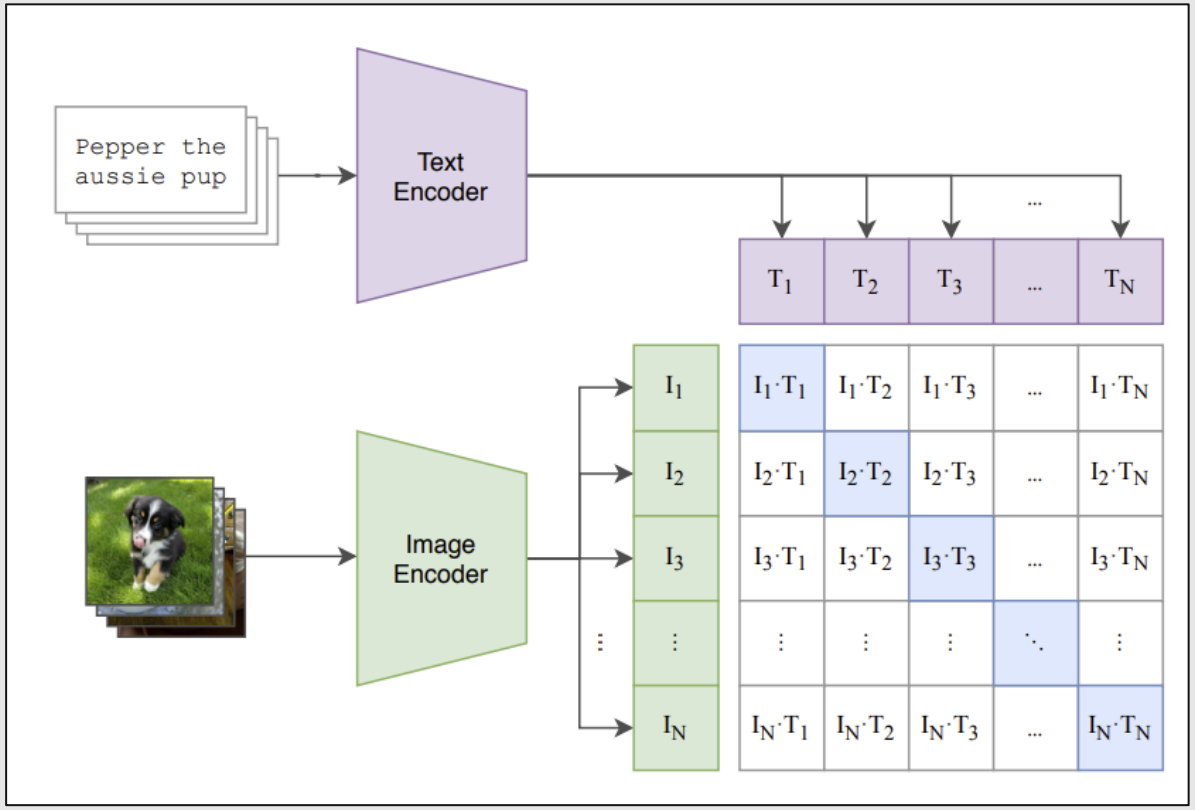

Radford, Alec, et al. "Learning transferable visual models from natural language supervision." International conference on machine learning. PmLR, 2021.

Modele językowe

- Większość współcześnie używanych modeli językowych jest trenowanych w oparciu o wpół nadzorowane uczenie – np. przewidywanie słów w zdaniu
- Ciąg dalszy nastąpi…

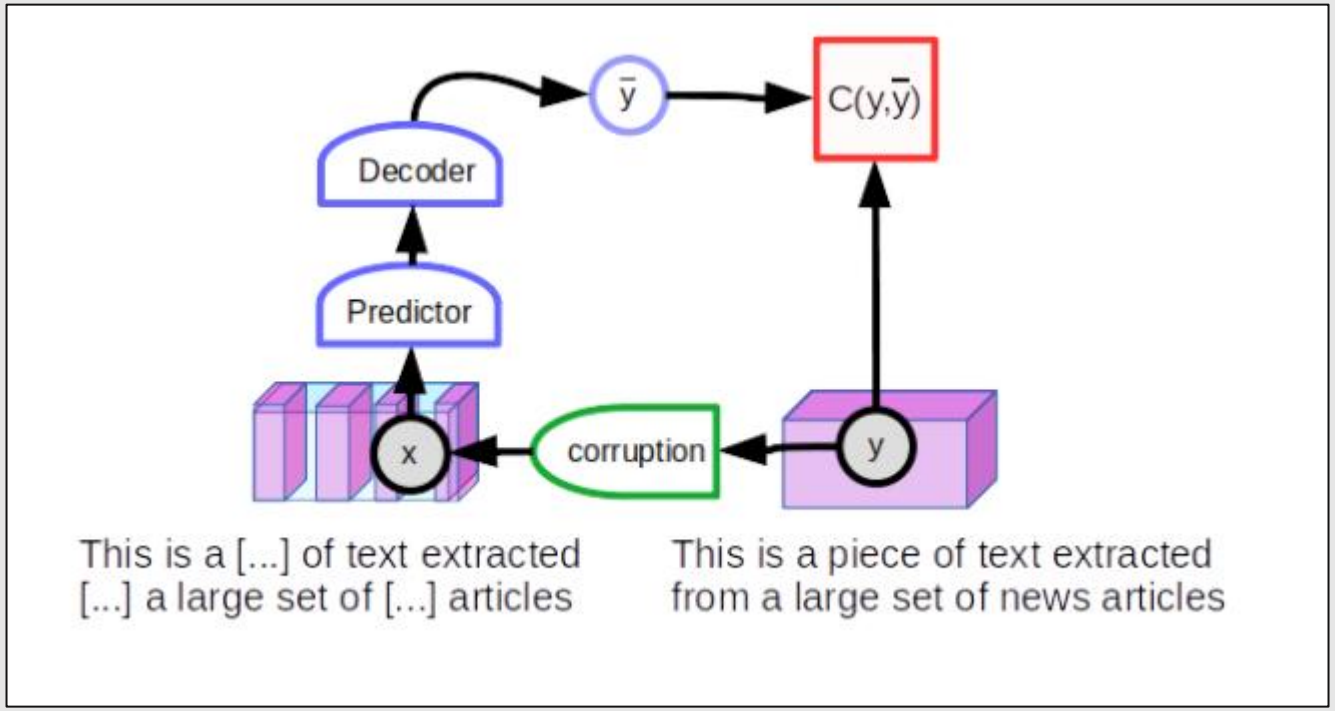

Devlin, Jacob, et al. "Bert: Pre-training of deep bidirectional transformers for language understanding." *arXiv preprint arXiv:1810.04805* (2018).

Podsumowanie

- Metody nadzorowane posiadają swoje ograniczenia i wymagają kosztownego opisywania danych
- Metody nienadzorowane np. autoenkodery pozwalają na uczenie się niskopoziomowych reprezentacji danych
- Metody samonadzorowane mogą być stosowane jako alternatywa do metod nienadzorowanych przy uczeniu reprezentacji
  Więcej szczegółów:
  https://youtu.be/7I0Qt7GALVk - Yann LeCun o Self-supervised learning

Warsaw University of Technology

Autoenkodery generatywne

Kamil Deja

Autoenkoder generatywny

- Działający w oparciu o autoenkodery
- Dodatkowa normalizacja na warstwie ukrytej wymuszająca rozkład normalny jej wyjścia
- Możliwość generowania nowych przykładów z losowych wartości o rozkładzie normalnym podawanych na warstwę ukrytą

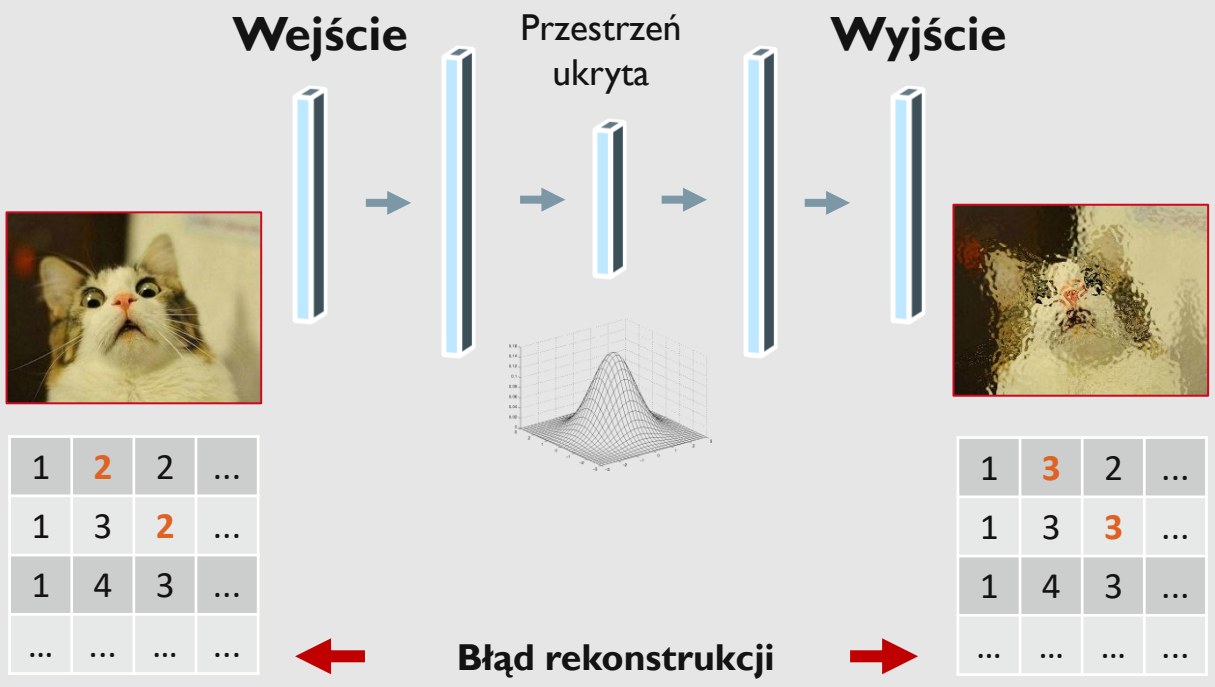

Modele probabilistyczne z przestrzenią ukrytą

- Wprowadzamy model w ramach którego uczymy się przestrzeni ukrytej z której możemy losować reprezentację przykładu **z**, na podstawie której losujemy przykład ***x*** z warunkowego prawdopodobieństwa $p(x|z)$
- Prawdopodobieństwo łączne dla takiego modelu opisuje funkcja:
$$p(x,z) = p(x|z)p(z)$$
- W trakcie treningu mamy jednak dostęp tylko do ***x***, powinniśmy więc zsumować p-ństwa dla wszystkich **z**:
$$p(x) = \int p(x|z)p(z)dz$$

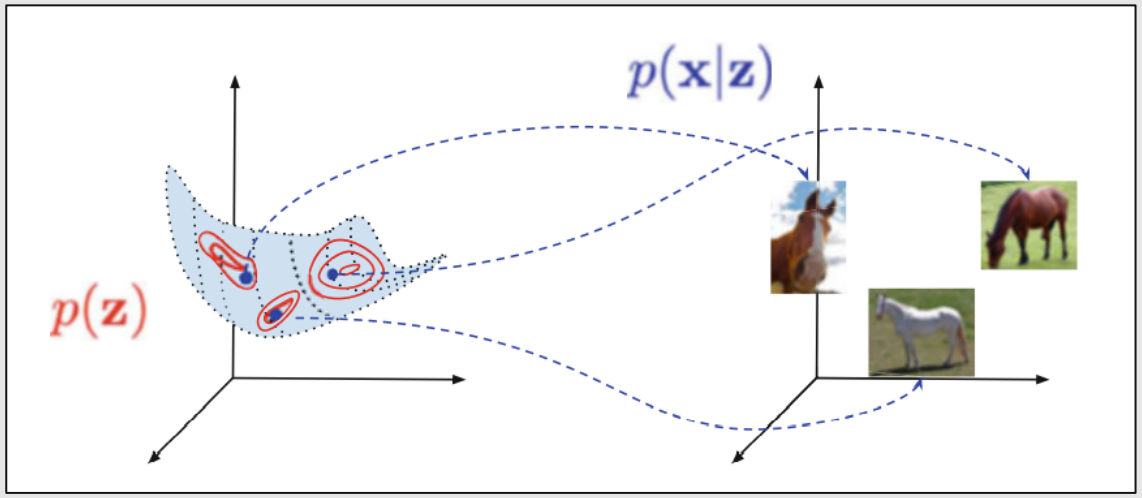

Aproksymacja rozkładu (Variational Inference)

- Aproksymacja Monte Carlo rozkładu *p(x)*:

$$
\begin{aligned}
p(\mathbf{x}) &= \int p(\mathbf{x} \mid \mathbf{z}) p(\mathbf{z}) \mathrm{d}\mathbf{z} \\
&= \mathbb{E}_{\mathbf{z} \sim p(\mathbf{z})}[p(\mathbf{x} \mid \mathbf{z})] \\
&\approx \frac{1}{K} \sum_{k} p(\mathbf{x} \mid \mathbf{z}_k),
\end{aligned}
$$

- Dla wielowymiarowego z – przekleństwo wymiarowości

Alternatywa - variational inference:

$$
\begin{aligned}
\ln p(\mathbf{x}) &= \ln \int p(\mathbf{x}|\mathbf{z}) p(\mathbf{z}) \, \mathrm{d}\mathbf{z} \\
&= \ln \int \frac{q_\phi(\mathbf{z})}{q_\phi(\mathbf{z})} p(\mathbf{x}|\mathbf{z}) p(\mathbf{z}) \, \mathrm{d}\mathbf{z} \\
&= \ln \mathbb{E}_{\mathbf{z} \sim q_\phi(\mathbf{z})} \left[\frac{p(\mathbf{x}|\mathbf{z}) p(\mathbf{z})}{q_\phi(\mathbf{z})} \right] \\
&\geq \mathbb{E}_{\mathbf{z} \sim q_\phi(\mathbf{z})} \ln \left[\frac{p(\mathbf{x}|\mathbf{z}) p(\mathbf{z})}{q_\phi(\mathbf{z})} \right] \\
&= \mathbb{E}_{\mathbf{z} \sim q_\phi(\mathbf{z})} \left[\ln p(\mathbf{x}|\mathbf{z}) + \ln p(\mathbf{z}) - \ln q_\phi(\mathbf{z}) \right] \\
&= \mathbb{E}_{\mathbf{z} \sim q_\phi(\mathbf{z})} \left[\ln p(\mathbf{x}|\mathbf{z}) \right] - \mathbb{E}_{\mathbf{z} \sim q_\phi(\mathbf{z})} \left[\ln q_\phi(\mathbf{z}) - \ln p(\mathbf{z}) \right].
\end{aligned}
$$

Dla rozkładu gaussowskiego $\phi = \{\mu, \sigma^2\}$

ELBO – Evidence Lower BOund

- Do tej pory:

$$\ln \mathrm{p}(\mathrm{x}) \geq \mathbb{E}_{\mathbf{z}\sim q_\phi(\mathbf{z})}[\ln p\,(\mathbf{x} \mid \mathbf{z})] - \mathbb{E}_{\mathbf{z}\sim q_\phi(\mathbf{z})}\left[\ln q_\phi\,(\mathbf{z}) - \ln p\,(\mathbf{z})\right]$$

- Uwzględnijmy nasz szczególny przypadek $q_\phi(z|x)$ zamiast $q_\phi(z)$, co daje nam strukturę autoenkodera:
  $q_\phi(z|x)$ - stochastyczny enkoder
  $p(x|z)$ - stochastyczny dekoder

  Z dolną granicą logarytmu funkcji wiarygodności (ELBO):

$$\ln \mathrm{p}(\mathrm{x}) \geq \underbrace{\mathbb{E}_{\mathbf{z}\sim q_\phi(\mathbf{z}|\mathbf{x})}[\ln p\,(\mathbf{x} \mid \mathbf{z})]}_{\text{Błąd rekonstrukcji}} - \underbrace{\mathbb{E}_{\mathbf{z}\sim q_\phi(\mathbf{z}|\mathbf{x})}\left[\ln q_\phi\,(\mathbf{z}|\mathbf{x}) - \ln p\,(\mathbf{z})\right]}_{\text{Regularyzacja}}$$

Wariacyjne autoenkodery (VAE)

- Enkoder zwracający wektor średnich i odchyleń standardowych
- Dekoder dekodujący wylosowany punkt z przestrzeni ukrytej
- Funkcja straty – ELBO!

$$\ln \mathrm{p}(\mathrm{x}) \geq \mathbb{E}_{\mathbf{z}\sim q_\phi(\mathbf{z}|\mathbf{x})}[\ln p\,(\mathbf{x} \mid \mathbf{z})] - \mathbb{E}_{\mathbf{z}\sim q_\phi(\mathbf{z}|\mathbf{x})}\left[\ln q_\phi\,(\mathbf{z}|\mathbf{x}) - \ln p\,(\mathbf{z})\right]$$

- Inaczej:

$$\ln \mathrm{p}(\mathrm{x}) \geq \mathbb{E}_{\mathbf{z}\sim q_\phi(\mathbf{z}|\mathbf{x})}[\ln p\,(\mathbf{x} \mid \mathbf{z})] - \mathrm{D}_{KL}(q_\phi(z|x)||p(z))$$

Alternatywnie $||p(x|z), x||$

Zazwyczaj rozkład normalny

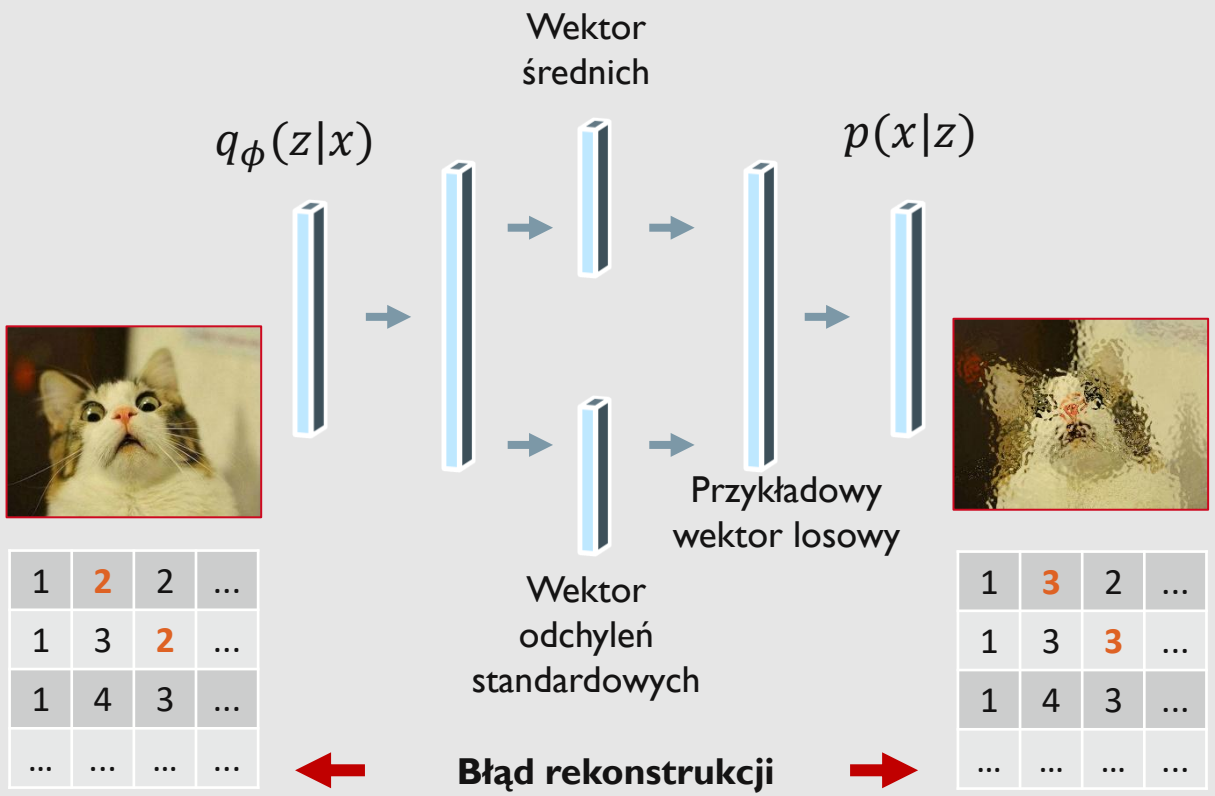

Reparametrization trick

- Jak propagować błąd przy niespójnym przepływie?
- Wyniesienie losowości poza przepływ sieci
- Zamiast:

$$z \sim N(\mu, \sigma^2)$$

- Możemy obliczyć:

$$\epsilon \sim N(0, I)$$
$$z = \mu + \sigma * \epsilon$$

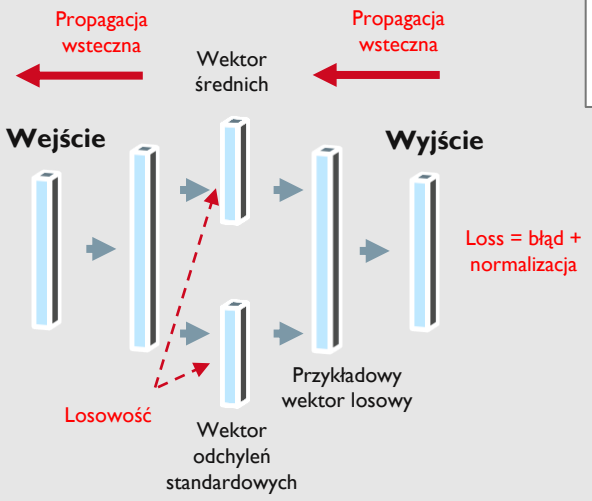

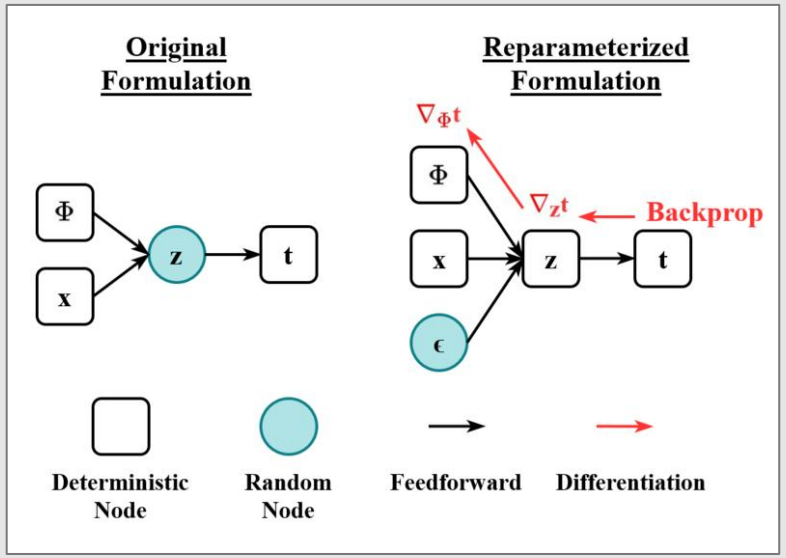

Wariacyjny autoenkoder

- Generowanie nowych próbek poprzez losowanie zmiennych ukrytych z i rekonstrukcję za pomocą dekodera
- Wiele rozszerzeń:
  - Hierarchiczne VAE – wiele ukrytych przestrzeni
  - Conditional VAE – dodanie warunkowania do generowanych przykładów
  - β-VAE – dodatkowa normalizacja wymuszająca dekompozycję przestrzeni ukrytej
  - …